

# Seminário — Um Problema Real do Kaggle

## Bases 5 — Ciência de Dados · UnDF · 2026.2

Prof. Douglas Braga

**Apresentação: 16 de dezembro de 2026 (aula 18). Peso: 40% da nota. Em duplas.**

### O que é o seminário

Cada dupla escolhe um dos cinco conjuntos de dados abaixo, todos do Kaggle, e resolve o problema de ponta a ponta: lê o dado como ele foi publicado, descreve e explora, separa o teste, prepara, compara modelos, escolhe, mede e diz o que o resultado permite e não permite concluir.

A nota **não** depende do desempenho no ranking do Kaggle nem de chegar ao menor erro da turma. O que se avalia é o raciocínio: por que cada decisão foi tomada, o que o dado sustenta e onde o resultado para de valer. Uma tentativa que não funcionou, bem explicada, vale mais que um número bom sem explicação.

- **Duplas.** Mais de uma dupla pode escolher o mesmo conjunto.
- **Formato:** 15 minutos de apresentação e 5 de arguição.
- **Entrega:** a apresentação e o notebook. O link do notebook é enviado pelo AVA até o dia da apresentação, de preferência de um repositório do GitHub aberto no Colab (serve também o link do Colab com acesso de leitura). O notebook precisa rodar do começo ao fim (*Executar tudo*).

### 1. Os cinco problemas

Baixe o dado direto do Kaggle (é preciso criar uma conta gratuita). A página de cada conjunto traz a descrição das colunas e a discussão da comunidade, e ler essa página faz parte do trabalho.

#### 1.1. Faltas a consultas médicas

<https://www.kaggle.com/datasets/joniarroba/noshowappointments>

**O paciente vai faltar à consulta marcada?** Cerca de 110 mil agendamentos da rede pública de saúde de Vitória (ES), com idade, sexo, bairro, condições de saúde, participação no Bolsa Família e se o paciente recebeu SMS de lembrete. Classificação binária.

#### 1.2. Cancelamento de reserva de hotel

<https://www.kaggle.com/datasets/jessemostipak/hotel-booking-demand>

**A reserva vai ser cancelada?** Cerca de 119 mil reservas de dois hotéis em Portugal, um urbano e um resort, com antecedência da reserva, datas, país de origem, canal de venda, tipo de quarto, depósito e tarifa. Classificação binária.

#### 1.3. Carros usados nos Estados Unidos

<https://www.kaggle.com/datasets/austinreese/craigslist-carstrucks-data>

**Quanto pedir por um carro usado?** Cerca de 427 mil anúncios do site Craigslist, com fabricante, modelo, ano, quilometragem, estado de conservação, combustível, câmbio, cor e localização. Regressão. O arquivo tem 1,4 GB: leia só as colunas de que precisa.

#### 1.4. Salários na área de dados no Brasil

<https://www.kaggle.com/datasets/datahackers/state-of-data-brazil-20242025>

**Em que faixa salarial está um profissional de dados?** A pesquisa *State of Data Brazil 2024-2025*, da comunidade Data Hackers, com cerca de 5 mil respostas de profissionais de dados sobre formação, cargo, senioridade, estado, setor, ferramentas e linguagens. A resposta é a faixa salarial, uma de 13 faixas ordenadas. Classificação multiclasse.

## 1.5. Municípios brasileiros

<https://www.kaggle.com/datasets/crisparada/brazilian-cities>

**Que tipos de município existem no Brasil?** Uma linha por município, com população por faixa etária, IDHM, PIB e valor adicionado por setor, empresas por atividade, frota, agências bancárias, hotéis, coordenadas e altitude. Não há resposta para prever: o problema é de aprendizado não supervisionado, com componentes principais e agrupamento.

## 2. O roteiro

A apresentação segue as etapas abaixo, nesta ordem. **Todos os tópicos listados são cobrados.**

### 1. A pergunta

- o que se quer prever, e em que momento
- o que é uma linha da tabela
- a resposta

### 2. Descrição e análise exploratória (antes de qualquer modelo)

- dicionário das colunas
- tipo de cada coluna: numérica (contínua ou discreta) ou categórica (nominal, ordinal ou binária); onde o tipo atribuído na leitura do arquivo está errado
- valores faltantes e o que significam
- linhas repetidas
- valores extremos e impossíveis
- distribuição da resposta, só no treino
- gráficos descritivos, cada um com uma conclusão

### 3. Separação do teste

- como e por que a divisão foi feita
- colunas que carregam a resposta
- linhas que aparecem dos dois lados da divisão

### 4. Pré-processamento

- faltantes, categorias e escalas
- ajustado só no treino, junto com o modelo

### 5. Comparação de modelos

- linha de base
- pelo menos dois modelos, por validação cruzada
- métrica escolhida pela pergunta

### 6. Ajuste de hiperparâmetros

- o que foi variado e o que foi escolhido, por validação cruzada

### 7. Resultado no teste

- teste usado uma única vez
- erro na unidade e na métrica da pergunta
- onde o modelo erra mais

## 8. Limites

- tentativas que não funcionaram
- o que o resultado não autoriza a concluir

## Municípios

Sem resposta, sem teste e sem linha de base. As etapas 1 e 2 valem inteiras; as demais viram:

- escala das colunas e valores por habitante
- componentes principais: variância explicada e cargas
- agrupamento e escolha do número de grupos
- interpretação dos grupos, inclusive no mapa
- estabilidade dos grupos com outras escolhas
- limites

## 3. Uso de IA e de notebooks públicos

Ferramentas de IA (ChatGPT, Claude, Gemini, Copilot e afins) e os notebooks públicos do Kaggle podem ser usados. Quem usar precisa declarar, numa seção no fim do notebook:

- **o que** foi usado: a ferramenta, ou o link do notebook do Kaggle;
- **em que parte** do trabalho;
- **como** foi usado: para entender um conceito, corrigir um erro, sugerir um gráfico, adaptar um trecho de código.

Usar como apoio é permitido; copiar uma solução pronta não é. O código e as decisões apresentados precisam ser da dupla, mesmo quando partiram de uma sugestão.

**A dupla precisa saber explicar tudo o que apresenta**, inclusive o que veio da IA ou de um notebook público. Na arguição, uma decisão que a dupla não sabe explicar não conta.

## 4. Calendário

| Data        | O que acontece                                                                                                                                                                          |
|-------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 07/10       | Divulgação destas instruções                                                                                                                                                            |
| 14/10 (HPE) | Horário protegido para estudo, <b>remoto e assíncrono</b> : não há aula presencial. A dupla usa o horário para se formar, ler as páginas dos cinco conjuntos no Kaggle e escolher o seu |
| até 21/10   | A dupla envia pelo AVA os nomes das duas pessoas e o problema escolhido                                                                                                                 |
| 16/12       | Apresentações, em ordem sorteada na hora; prazo para enviar pelo AVA o link do notebook                                                                                                 |

## 5. Critérios de avaliação

| Critério                                                                                                                                           | Peso |
|----------------------------------------------------------------------------------------------------------------------------------------------------|------|
| <b>Descrição e análise exploratória:</b> a unidade e a resposta, o tipo de cada coluna pela taxonomia, faltantes, extremos, gráficos com conclusão | 25%  |
| <b>Avaliação honesta:</b> a divisão, o vazamento, a métrica e a linha de base                                                                      | 25%  |
| <b>Modelagem justificada:</b> o pré-processamento e a comparação de modelos, cada escolha com o porquê                                             | 20%  |
| <b>Limites e tentativas que falharam</b>                                                                                                           | 15%  |

| Critério                                                                         | Peso |
|----------------------------------------------------------------------------------|------|
| <b>Arguição, individual:</b> cada pessoa da dupla responde ao menos uma pergunta | 15%  |

A arguição é a única parte individual: as duas pessoas da dupla podem ter notas diferentes nela.